

LAPORAN
ANALITIK DAN VISUALISASI DATA
ANALISIS DATA PENJUALAN SUPERSTORE MENGGUNAKAN
EXPLORATORY DATA ANALYSIS (EDA)



DISUSUN OLEH:
CONDRADO ALAIN SHARON
(2509116069)

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN

2026

DAFTAR ISI

DAFTAR ISI	i
DAFTAR GAMBAR	ii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Tujuan	1
BAB II METODOLOGI ANALISIS	2
2.1 Data Understanding	2
2.2 Data Quality Check	3
2.3 Data Reduction.....	4
BAB III EXPLORATORY DATA ANALYSIS (EDA)	6
3.1 Distribution (Distribusi Data).....	6
3.1.1 Distribusi Sales	6
3.1.2 Distribusi Profit.....	7
3.2 Relationship (Hubungan Antar Variabel)	7
3.2.1 Relationship antara Discount dan Profit	7
3.2.2 Relationship antara Sales dan Profit	8
3.3 Comparison (Perbandingan Antar Kategori).....	8
3.4 Composition (Komposisi Data).....	9
BAB 4 PENUTUP	11
4.1 Kesimpulan.....	11
4.2 Insight dan Rekomendasi	11

DAFTAR GAMBAR

Gambar 2. 1 Deskripsi Dataset	2
Gambar 2. 2 Hasil Pengecekan Missing Values	3
Gambar 2. 3 Hasil Penghapusan data yang terduplikasi	4
Gambar 2. 4 Hasil Pengecekan <i>Outliers</i> . Kolom yang terdampak tidak di atasi karena mengandung <i>Insight</i> penting.....	4
Gambar 2. 5 Proses penghapusan Kolom Country dihapus dikarenakan hanya mengandung satu nilai saja.....	5
Gambar 3. 1 Visualisasi untuk melihat distribusi Sales.....	6
Gambar 3. 2 Hasil Visualisasi untuk menganalisis Distribusi Profit.....	7
Gambar 3. 3 Visualisasi untuk melihat hubungan antara kolom Discount dengan Profit.....	7
Gambar 3. 4 Visualisasi untuk melihat hubungan antara Sales dan Profit	8
Gambar 3. 5 Visualisasi boxplot untuk melihat perbandingan Profit per Kategori.....	9
Gambar 3. 6 Visualisasi untuk melihat komposisi kategori	10

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dataset yang digunakan dalam analisis ini merupakan data penjualan dari sebuah perusahaan retail (Superstore). Dataset ini berisi informasi mengenai transaksi penjualan, seperti kategori produk, jumlah penjualan (*sales*), keuntungan (*profit*), diskon, wilayah, serta informasi pelanggan.

Dalam kegiatan bisnis, penjualan dan keuntungan merupakan dua hal yang sangat penting untuk diperhatikan. Namun, tidak semua penjualan yang tinggi selalu menghasilkan keuntungan yang besar. Hal ini dapat dipengaruhi oleh berbagai faktor, seperti pemberian diskon yang terlalu besar, jenis produk yang dijual, maupun kondisi pasar di wilayah tertentu.

Selain itu, setiap kategori produk dan wilayah juga dapat memiliki performa yang berbeda. Terdapat kemungkinan bahwa suatu kategori memiliki penjualan tinggi tetapi keuntungan rendah, atau sebaliknya. Tanpa adanya analisis yang tepat, kondisi tersebut sulit untuk dipahami secara menyeluruh.

Oleh karena itu, diperlukan analisis data untuk memahami pola penjualan dan keuntungan, serta mengidentifikasi faktor-faktor yang memengaruhinya. Dengan memahami pola tersebut, diharapkan dapat diperoleh gambaran yang lebih jelas mengenai kondisi bisnis, sehingga dapat membantu dalam pengambilan keputusan yang lebih tepat.

1.2 Tujuan

Tujuan dari analisis data ini adalah untuk mendapatkan *insight* yang dapat membantu memahami kondisi penjualan dan keuntungan secara lebih baik. Adapun tujuan yang ingin dicapai antara lain:

1. Mengetahui kategori produk yang memiliki penjualan dan profit tertinggi
2. Menganalisis hubungan antara sales dan profit. Apakah jika penjualan naik maka profit naik atau sebaliknya.
3. Melihat apakah ada pengaruh diskon terhadap keuntungan.
4. Mengidentifikasi wilayah dengan performa penjualan terbaik.
5. Menemukan pola atau tren yang memberi keuntungan sehingga dapat membantu pengambilan keputusan.

BAB II

METODOLOGI ANALISIS

2.1 Data Understanding

Pada tahap ini dilakukan pemahaman terhadap dataset yang digunakan dalam analisis. Dataset yang digunakan merupakan data penjualan Superstore yang berisi informasi transaksi, seperti kategori produk, penjualan (*sales*), keuntungan (*profit*), diskon, wilayah, serta atribut lainnya.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9994 entries, 0 to 9993
Data columns (total 13 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Ship Mode       9994 non-null   object
1   Segment         9994 non-null   object
2   Country         9994 non-null   object
3   City            9994 non-null   object
4   State           9994 non-null   object
5   Postal Code     9994 non-null   int64
6   Region          9994 non-null   object
7   Category        9994 non-null   object
8   Sub-Category    9994 non-null   object
9   Sales           9994 non-null   float64
10  Quantity        9994 non-null   int64
11  Discount        9994 non-null   float64
12  Profit          9994 non-null   float64
dtypes: float64(3), int64(2), object(8)
memory usage: 1015.1+ KB
```

Gambar 2. 1 Deskripsi Dataset

Berdasarkan hasil pengecekan, dataset memiliki 9994 baris data (record) dan 13 kolom (atribut) yang menggambarkan kondisi transaksi penjualan. Dataset ini terdiri dari banyak data transaksi dengan berbagai informasi yang saling berkaitan.

Beberapa kolom utama dalam dataset antara lain:

- Ship Mode: Metode pengiriman barang kepada pelanggan (misalnya Standard Class, Second Class, dll)
- Segment: Segmen pelanggan yang melakukan pembelian (Consumer, Corporate, Home Office)
- City: Kota tempat penjualan dilakukan
- State: Negara bagian tempat penjualan dilakukan (setara Provinsi)
- Region: Wilayah geografis penjualan (misalnya West, East, Central, South)
- Category: Kategori utama produk yang dijual (misalnya Furniture, Office Supplies, Technology)

- Sub-Category: Sub-kategori dari produk yang lebih spesifik
- Sales: Nilai penjualan dari transaksi (dalam satuan mata uang)
- Quantity: Jumlah unit produk yang terjual dalam satu transaksi
- Discount: Besar diskon yang diberikan pada transaksi (dalam bentuk proporsi)
- Profit: Keuntungan yang diperoleh dari setiap transaksi

Kolom Sales dan Profit merupakan variabel utama dalam analisis karena berkaitan langsung dengan performa bisnis, sedangkan kolom lainnya digunakan untuk melihat pola berdasarkan kategori, wilayah, dan karakteristik transaksi.

Selain itu, dilakukan juga statistik deskriptif untuk mengetahui gambaran umum data, seperti nilai rata-rata, nilai minimum, dan maksimum, sehingga dapat membantu dalam memahami kondisi awal dataset sebelum dilakukan analisis lebih lanjut.

2.2 Data Quality Check

Tahap ini dilakukan untuk memastikan bahwa data yang digunakan sudah dalam kondisi baik dan siap untuk dianalisis. Beberapa pengecekan yang dilakukan antara lain:

- **Missing Values**


Dilakukan pengecekan untuk mengetahui apakah terdapat data yang hilang. Berdasarkan hasil analisis, tidak ditemukan nilai yang hilang sehingga data dapat langsung digunakan.

Null Ratio in %	
Ship Mode	0.0
Segment	0.0
Country	0.0
City	0.0
State	0.0
Postal Code	0.0
Region	0.0
Category	0.0
Sub-Category	0.0
Sales	0.0
Quantity	0.0
Discount	0.0
Profit	0.0

Gambar 2. 2 Hasil Pengecekan Missing Values

- **Duplicated Data**

Dilakukan pengecekan terhadap data duplikat. Ditemukan beberapa data yang sama, sehingga dilakukan penghapusan data yang terduplikasi agar tidak memengaruhi hasil analisis.



```
df[df.duplicated(keep=False)].sort_values(by=list(df.columns))
```

Ship Mode	Segment	Country	City	State	Postal Code	Region	Category	Sub-Category	Sales	Quantity	Discount	Profit
-----------	---------	---------	------	-------	-------------	--------	----------	--------------	-------	----------	----------	--------

Gambar 2. 3 Hasil Penghapusan data yang terduplikasi

- **Inconsistent Values**

Dilakukan pengecekan pada data kategorikal untuk memastikan tidak ada perbedaan penulisan. Hasilnya menunjukkan bahwa data sudah konsisten dan tidak memerlukan perbaikan.

- **Outliers**

Dilakukan pengecekan nilai ekstrem pada beberapa variabel numerik seperti Sales, Profit, Quantity, dan Discount. Ditemukan adanya outlier, namun nilai tersebut tetap dipertahankan karena masih relevan dan dapat memberikan insight penting.

	Kolom	Jumlah Outliers	Persentase Outliers (%)
0	Sales	1167	11.696903
1	Profit	1881	18.853363
2	Quantity	170	1.703919
3	Discount	855	8.569710

Gambar 2. 4 Hasil Pengecekan *Outliers*. Kolom yang terdampak tidak di atasi karena mengandung *Insight* penting

2.3 Data Reduction

Pada tahap ini dilakukan penyederhanaan data dengan menghapus kolom yang tidak memberikan informasi tambahan. Dalam kasus ini, kolom **Country** dihapus karena seluruh data hanya memiliki satu nilai yang sama, sehingga tidak memiliki variasi dan tidak berkontribusi dalam proses analisis. Dengan demikian, dataset menjadi lebih fokus pada variabel yang relevan.

```
df = df.drop(columns=['Country'])
```

Pengecekan:

```
df.columns
```

```
... Index(['Ship Mode', 'Segment', 'City', 'State', 'Postal Code', 'Region',
        'Category', 'Sub-Category', 'Sales', 'Quantity', 'Discount', 'Profit'],
        dtype='object')
```

Gambar 2. 5 Proses penghapusan Kolom Country dihapus dikarenakan hanya mengandung satu nilai saja

2.4 Metode Analisis

Analisis dilakukan menggunakan pendekatan **Exploratory Data Analysis (EDA)** untuk memahami pola dan hubungan dalam data. Beberapa metode visualisasi yang digunakan antara lain:

- **Distribution (Distribusi Data)**
Menggunakan histogram untuk melihat sebaran data pada variabel Sales dan Profit.
- **Relationship (Hubungan Antar Variabel)**
Menggunakan scatter plot untuk melihat hubungan antara variabel, seperti Sales terhadap Profit dan Discount terhadap Profit.
- **Comparison (Perbandingan)**
Menggunakan boxplot untuk membandingkan profit antar kategori produk.
- **Composition (Komposisi Data)**
Menggunakan pie chart untuk melihat proporsi data berdasarkan kategori.

Melalui metode ini, diharapkan dapat diperoleh insight yang dapat membantu memahami kondisi penjualan dan faktor-faktor yang memengaruhi profit.


BAB III

EXPLORATORY DATA ANALYSIS (EDA)

3.1 Distribution (Distribusi Data)

Pada tahap ini, dilakukan analisis untuk melihat sebaran data pada beberapa variabel utama, yaitu Sales dan Profit. Tujuannya adalah untuk memahami bagaimana pola data secara umum, apakah data cenderung merata atau terdapat perbedaan yang cukup jauh antar nilai. Kolom yang akan dianalisis distribusinya adalah kolom Sales dan kolom Profit dengan visualisasi menggunakan grafik Histogram. Khusus untuk Distribusi Sales, visualisasi yang digunakan adalah Histogram dengan transformasi log (log scale).


3.1.1 Distribusi Sales



Gambar 3. 1 Visualisasi untuk melihat distribusi Sales

Berdasarkan visualisasi histogram dengan transformasi log, terlihat bahwa sebagian besar data berada pada nilai penjualan menengah. Di sisi lain, masih terdapat cukup banyak transaksi dengan nilai penjualan kecil, serta beberapa transaksi dengan nilai yang sangat tinggi. Oleh karena itu, bisa ditarik Kesimpulan bahwa sebagian besar transaksi memiliki nilai penjualan menengah, sementara transaksi dengan nilai sangat tinggi hanya terjadi dalam jumlah kecil. Hal ini menunjukkan bahwa penjualan tidak merata, dimana hanya sebagian kecil transaksi yang memberikan kontribusi penjualan yang sangat besar.

3.1.2 Distribusi Profit




Gambar 3. 2 Hasil Visualisasi untuk menganalisis Distribusi Profit

Berdasarkan visualisasi, terlihat bahwa sebagian besar nilai profit berada di sekitar nol, baik dalam kondisi keuntungan kecil maupun kerugian kecil. Selain itu, terdapat cukup banyak transaksi yang mengalami kerugian, serta beberapa transaksi dengan keuntungan maupun kerugian yang sangat besar. Oleh karena itu, bisa ditarik Kesimpulan bahwa profit tidak selalu stabil. Sebagian besar transaksi hanya menghasilkan keuntungan kecil, dan terdapat cukup banyak transaksi yang mengalami kerugian. Hal ini menunjukkan bahwa perlu dilakukan analisis lebih lanjut untuk memahami faktor yang memengaruhi profit.

3.2 Relationship (Hubungan Antar Variabel)

Pada tahap ini, dilakukan analisis untuk melihat hubungan antara variabel-variabel utama dalam dataset. Tujuannya adalah untuk mengetahui apakah terdapat hubungan antara penjualan, diskon, dan profit. Untuk analisis ini, digunakan visualisasi Scatter Plot.

3.2.1 Relationship antara Discount dan Profit




Gambar 3. 3 Visualisasi untuk melihat hubungan antara kolom Discount dengan Profit

Berdasarkan visualisasi scatter plot, terlihat bahwa semakin tinggi nilai diskon, profit cenderung menurun. Pada nilai diskon yang tinggi, sebagian besar transaksi berada pada kondisi kerugian.

Kesimpulannya adalah diskon memiliki pengaruh yang cukup besar terhadap profit. Pemberian diskon yang tinggi berpotensi menurunkan keuntungan, bahkan dapat menyebabkan kerugian.

3.2.2 Relationship antara Sales dan Profit



Gambar 3. 4 Visualisasi untuk melihat hubungan antara Sales dan Profit


Berdasarkan visualisasi, terlihat bahwa terdapat kecenderungan hubungan positif antara sales dan profit, dimana peningkatan penjualan umumnya diikuti dengan peningkatan keuntungan. Namun, terdapat beberapa transaksi dengan nilai penjualan tinggi yang justru mengalami kerugian.

Kesimpulannya adalah, penjualan yang tinggi tidak selalu menjamin keuntungan yang tinggi. Faktor lain seperti diskon atau jenis produk juga memengaruhi profit.

3.3 Comparison (Perbandingan Antar Kategori)

Pada tahap ini, dilakukan analisis untuk membandingkan performa profit antar kategori produk. Tujuannya adalah untuk mengetahui kategori produk yang paling menguntungkan dan yang memiliki performa rendah. Untuk itu digunakan visualisasi berupa Boxplot. Boxplot digunakan karena dapat menunjukkan sebaran data secara lebih lengkap, termasuk median, variasi data, dan outlier, sehingga lebih informatif dibandingkan dengan visualisasi lain,

khususnya bar chart yang sering digunakan jika menganalisis perbandingan dan hanya menampilkan nilai rata-rata.




Gambar 3. 5 Visualisasi boxplot untuk melihat perbandingan Profit per Kategori

Berdasarkan visualisasi boxplot, terlihat bahwa kategori Technology memiliki nilai profit yang lebih tinggi dibandingkan kategori lainnya. Hal terlihat dari kotak yang lebih tinggi dari kategori lainnya, serta titik titiknya lebih tinggi dan tersebar disbanding lainnya. Sementara itu, kategori Furniture cenderung memiliki profit yang rendah dan sering mengalami kerugian. Kategori Office Supplies berada di antara keduanya dengan variasi yang cukup besar.

Kesimpulannya adalah kategori Technology merupakan kategori yang paling menguntungkan, sedangkan Furniture memiliki performa paling rendah. Hal ini menunjukkan bahwa jenis produk memiliki pengaruh yang signifikan terhadap profit.

3.4 Composition (Komposisi Data)

Pada tahap ini, dilakukan analisis untuk melihat proporsi data berdasarkan kategori produk. Tujuannya adalah untuk mengetahui kategori mana yang paling dominan dalam dataset. Untuk komposisi ini, digunakan visualisasi pie chart karena lebih mudah dalam memudahkan dalam melihat proporsi masing-masing kategori dalam dataset.



Gambar 3. 6 Visualisasi untuk melihat komposisi kategori

Berdasarkan visualisasi pie chart, terlihat bahwa kategori **Office Supplies** memiliki proporsi terbesar dalam dataset, diikuti oleh **Furniture**, dan **Technology** memiliki proporsi paling kecil.

Kesimpulannya, Sebagian besar transaksi berasal dari kategori Office Supplies, namun jumlah transaksi yang besar tidak selalu berarti menghasilkan profit yang tinggi. Hal ini menunjukkan bahwa jumlah transaksi dan profit perlu dianalisis secara bersamaan.

BAB 4

PENUTUP

4.1 Kesimpulan

Berdasarkan hasil Exploratory Data Analysis (EDA) yang telah dilakukan, dapat disimpulkan bahwa pola penjualan dan keuntungan dalam dataset memiliki variasi yang cukup besar.

Sebagian besar transaksi memiliki nilai penjualan dan keuntungan yang relatif kecil. Namun, terdapat beberapa transaksi dengan nilai penjualan dan keuntungan yang sangat tinggi, serta beberapa transaksi yang mengalami kerugian cukup besar. Hal ini menunjukkan bahwa data tidak merata dan terdapat perbedaan yang signifikan antar transaksi.

Dari analisis hubungan antar variabel, diketahui bahwa penjualan (Sales) cenderung memiliki hubungan positif dengan keuntungan (Profit), dimana peningkatan penjualan umumnya diikuti dengan peningkatan keuntungan. Namun, hubungan ini tidak selalu konsisten karena terdapat beberapa transaksi dengan penjualan tinggi yang justru mengalami kerugian. Selain itu, diskon (Discount) memiliki pengaruh yang cukup besar terhadap profit, dimana semakin tinggi diskon yang diberikan, profit cenderung menurun.

Dari sisi kategori produk, kategori Technology memberikan keuntungan paling tinggi, meskipun jumlah transaksinya lebih sedikit. Sementara itu, kategori Furniture memiliki performa yang paling rendah dan cenderung sering mengalami kerugian. Kategori Office Supplies memiliki jumlah transaksi paling banyak, namun tidak selalu menghasilkan keuntungan yang tinggi.

Kesimpulannya adalah, profit tidak hanya dipengaruhi oleh jumlah penjualan, tetapi juga oleh faktor lain seperti diskon dan jenis produk.

4.2 Insight dan Rekomendasi

Berdasarkan hasil analisis yang telah dilakukan, terdapat beberapa insight penting yang dapat digunakan sebagai dasar dalam pengambilan keputusan.

Pertama, pemberian diskon memiliki pengaruh besar terhadap profit. Diskon yang terlalu tinggi dapat menyebabkan penurunan keuntungan, bahkan kerugian. Oleh karena itu, perusahaan perlu lebih berhati-hati dalam menentukan strategi diskon.

Kedua, kategori Technology terbukti memberikan keuntungan yang paling tinggi. Hal ini menunjukkan bahwa perusahaan dapat lebih fokus pada kategori tersebut untuk meningkatkan profit.

Ketiga, kategori Furniture perlu mendapatkan perhatian lebih karena sering menghasilkan keuntungan yang rendah atau bahkan kerugian. Evaluasi terhadap strategi harga, biaya, dan diskon pada kategori ini perlu dilakukan.

Keempat, peningkatan penjualan tidak selalu menjamin peningkatan keuntungan. Oleh karena itu, perusahaan tidak hanya perlu fokus pada peningkatan sales, tetapi juga memastikan bahwa setiap transaksi tetap memberikan profit.

Dengan mempertimbangkan insight tersebut, diharapkan perusahaan dapat meningkatkan kinerja penjualan dan keuntungan secara lebih optimal.